

Práctica 1.1 — Probabilidad y Estadística

Análisis de la evolución poblacional mundial

Objetivo

Utilizar un conjunto de datos real para comprobar el funcionamiento del entorno de análisis de datos y aplicar medidas estadísticas descriptivas básicas utilizando Pandas y NumPy.

Actividad 1 — Identificación de la fuente

Propósito: reconocer la procedencia del conjunto de datos antes de utilizarlo y documentar correctamente su fuente.

Los datos utilizados en esta práctica provienen de **Our World in Data (OWID)**. La fuente original es **United Nations, World Population Prospects (2024)**.

Cita:

UN, World Population Prospects (2024) – processed by Our World in Data.
“Annual change in population – UN WPP” [dataset]. United Nations, “World Population Prospects”; United Nations, “World Population Prospects - Interim Update” [original data].

Preguntas

1. **¿Quién produjo originalmente los datos?** United Nations.
2. **¿Qué organización los procesa para su utilización en Our World in Data?** Our World in Data.
3. **¿Qué representa la variable que analizarás?** Representa el cambio anual de la población, es decir, cuánto aumenta o disminuye el número de habitantes de una entidad respecto al año anterior.

Actividad 2 — Carga y exploración de datos

Propósito: comprobar que el entorno de Python, Pandas y Jupyter funciona correctamente y realizar una primera exploración del dataset.

2.1 Importar las bibliotecas

```
In [1]: from pathlib import Path
import pandas as pd
import numpy as np
```

2.2 Cargar el archivo CSV

Se utiliza una ruta relativa para que el notebook funcione tanto desde la raíz del proyecto como desde la carpeta notebooks .

```
In [2]: raiz_proyecto = Path.cwd() if (Path.cwd() / "data").exists() else Path.cwd().parent
ruta_csv = raiz_proyecto / "data" / "raw" / "annual-population-growth" / "annual-po
df = pd.read_csv(ruta_csv)
df.head()
```

```
Out[2]:
```

	Entity	Code	Year	Annual change in population	Annual population change (Projected)
0	Afghanistan	AFG	1951	103163.0	NaN
1	Afghanistan	AFG	1952	108441.0	NaN
2	Afghanistan	AFG	1953	108919.0	NaN
3	Afghanistan	AFG	1954	111251.0	NaN
4	Afghanistan	AFG	1955	119027.0	NaN

2.3 Explorar el DataFrame

Se revisan las primeras filas, dimensiones, columnas, tipos de datos, estadísticas descriptivas, valores faltantes y cantidad de entidades.

```
In [3]: df.head()
```

```
Out[3]:
```

	Entity	Code	Year	Annual change in population	Annual population change (Projected)
0	Afghanistan	AFG	1951	103163.0	NaN
1	Afghanistan	AFG	1952	108441.0	NaN
2	Afghanistan	AFG	1953	108919.0	NaN
3	Afghanistan	AFG	1954	111251.0	NaN
4	Afghanistan	AFG	1955	119027.0	NaN

```
In [4]: print("Dimensiones:", df.shape)
print("Nombres de columnas:", df.columns.tolist())
print("\nTipos de datos:")
display(df.dtypes)
```

Dimensiones: (38400, 5)

Nombres de columnas: ['Entity', 'Code', 'Year', 'Annual change in population', 'Annual population change (Projected)']

Tipos de datos:

```
Entity          str
Code            str
Year            int64
Annual change in population    float64
Annual population change (Projected)  float64
dtype: object
```

In [5]: `df.describe()`

```
Out[5]:
```

	Year	Annual change in population	Annual population change (Projected)
count	38400.000000	1.868800e+04	1.971200e+04
mean	2025.500000	2.063019e+06	8.375481e+05
std	43.300872	9.440859e+06	5.816745e+06
min	1951.000000	-3.315935e+06	-2.291035e+07
25%	1988.000000	1.781000e+03	-9.742750e+03
50%	2025.500000	4.689800e+04	9.350000e+01
75%	2063.000000	3.021128e+05	1.411160e+05
max	2100.000000	9.337137e+07	7.206736e+07

In [6]: `print("Valores faltantes por columna:")`
`display(df.isnull().sum())`
`print("Cantidad de entidades diferentes:", df["Entity"].nunique())`

Valores faltantes por columna:

```
Entity          0
Code            1200
Year            0
Annual change in population    19712
Annual population change (Projected)  18688
dtype: int64
```

Cantidad de entidades diferentes: 256

Respuestas de la Actividad 2

1. **¿Cuántas filas y columnas tiene el dataset?** Tiene **38,400 filas y 5 columnas**.
2. **¿Qué tipo de datos contiene la variable Year ?** Es de tipo entero (int64).
3. **¿Existen valores faltantes?** Sí. Code tiene 1,200; Annual change in population , 19,712; y Annual population change (Projected) , 18,688. Entity y Year no tienen valores faltantes. Los faltantes de las dos variables poblacionales se deben a que una contiene datos históricos y la otra proyecciones.
4. **¿Cuántas entidades diferentes contiene el dataset?** Contiene **256 entidades**.

Actividad 3 — Estadística descriptiva

Propósito: aplicar medidas estadísticas básicas a una variable poblacional.

Se selecciona el año histórico **2020** y se analiza la variable `Annual change in population`. Se eliminan únicamente los valores faltantes de esta variable antes de calcular los estadísticos.

```
In [7]: variable = "Annual change in population"
df_2020 = df.loc[(df["Year"] == 2020) & df[variable].notna()].copy()
print("Registros históricos de 2020:", len(df_2020))
df_2020[["Entity", "Year", variable]].head()
```

Registros históricos de 2020: 256

```
Out[7]:
```

	Entity	Year	Annual change in population
69	Afghanistan	2020	1212852.0
219	Africa (UN)	2020	32815675.0
369	Albania	2020	-13061.0
519	Algeria	2020	747543.0
669	American Samoa	2020	-451.0

```
In [8]: cambio_2020 = df_2020[variable]

estadisticos_2020 = pd.Series({
    "Media": cambio_2020.mean(),
    "Mediana": cambio_2020.median(),
    "Varianza": cambio_2020.var(),
    "Desviación estándar": cambio_2020.std(),
    "Mínimo": cambio_2020.min(),
    "Máximo": cambio_2020.max(),
}, name="Cambio anual de población en 2020")

estadisticos_2020.to_frame().style.format("{:,.2f}")
```

```
Out[8]:
```

Cambio anual de población en 2020	
Media	2,124,908.85
Mediana	34,293.50
Varianza	90,687,335,031,103.64
Desviación estándar	9,522,989.82
Mínimo	-494,016.00
Máximo	75,707,590.00

```
In [9]: fila_minimo = df_2020.loc[cambio_2020.idxmin(), ["Entity", variable]]
fila_maximo = df_2020.loc[cambio_2020.idxmax(), ["Entity", variable]]

entidades_extremas = pd.DataFrame({
    "Mínimo": fila_minimo,
    "Máximo": fila_maximo,
}).T
entidades_extremas
```

```
Out[9]:
```

	Entity	Annual change in population
Mínimo	Venezuela	-494016.0
Máximo	World	75707590.0

```
In [10]: # Comprobación de la media y la mediana con NumPy
print("Media con NumPy:", np.mean(cambio_2020))
print("Mediana con NumPy:", np.median(cambio_2020))
```

Media con NumPy: 2124908.84765625

Mediana con NumPy: 34293.5

Respuestas de la Actividad 3

1. **¿Cuál es el valor de la media?** La media es **2,124,908.85 habitantes**.
2. **¿Cuál es el valor de la mediana?** La mediana es **34,293.50 habitantes**.
3. **¿Cuál es el valor de la desviación estándar?** La desviación estándar muestral es **9,522,989.82 habitantes**.
4. **¿Qué entidad presenta el valor mínimo y cuál el máximo?** **Venezuela** presenta el mínimo, con **-494,016 habitantes**, y **World** presenta el máximo, con **75,707,590 habitantes**. World aparece porque el dataset incluye agregados además de países.

Actividad 4 — Comprobación del entorno

Propósito: comprobar que el notebook está utilizando correctamente las herramientas configuradas para la práctica.

La siguiente celda muestra las versiones de Python, Pandas y NumPy del entorno virtual activo.

```
In [11]: import sys

print("Python:", sys.version)
print("Pandas:", pd.__version__)
print("NumPy:", np.__version__)
```

Python: 3.13.15 (tags/v3.13.15:4061bc4, Aug 5 2026, 13:05:39) [MSC v.1944 64 bit (AMD64)]

Pandas: 3.0.5

NumPy: 2.5.2

